

SOKKANAEM: 효율적이고 안정적인 비디오 깊이 추정을 위한 정확한 변화 게이팅 상태공간 모델

작업 초안 — 2026년 8월 19일. draft.md의 한국어판이며 내용은 동일하다. 저자·소속·학회 양식·정성 그림·에지 기기 실측은 추후 추가해야 한다. 아래의 정량 주장은 저장소에서 완료된 실험으로 범위를 제한한다.

절 상태 표식. 어떤 수치가 확정이고 어떤 것이 움직이는 중인지 제목에 표시한다:

- **[검증 중]** — 실행 중이거나 대기 중인 실험이 이 절의 결론을 직접 겨냥한다. 결론이 뒤집힐 수 있다.
- **[체크포인트 종속]** — 보고한 체크포인트에 대해 성립한다. 체크포인트가 바뀌면 수치가 움직이지만 정성적 주장까지 바뀔 것으로 보지는 않는다.
- 표식이 없는 절은 확정이다 — 구조·데이터에서 따라오거나, 재학습이 바뀌지 않는 측정이다.

초록

비디오 깊이 모델은 넓은 정적 영역을 프레임마다 반복 처리하며, 출력에 프레임 간 플리커가 발생하기 쉽다. 본 연구는 패치 수준 변화 감지를 선택적 상태공간 모델(SSM)의 이산화 단계에 연결한 소형 순환 비디오 깊이 모델 **SOKKANAEM**을 제안한다. 이진 활성 마스크 M 이 주어질 때 SSM의 시간 간격 Δ 를 $\tilde{\Delta} = M\Delta$ 로 대체한다. 정적 패치에서는 $\tilde{\Delta} = 0$ 이므로 $\tilde{A} = I$, $\tilde{B} = 0$ 이 되어 hidden state가 근사 복원되지 않고 정확히 복사된다. 시간 축 SSM은 위치별 기억을 보존하고, 공간축 SSM과 dense decoder가 공간 문맥과 깊이를 복원한다. 이동 카메라에서는 저해상도 전역 모션 보정(GMC) 뒤에 피쳐 공간 변화 감지를 적용한다.

4.19M 파라미터 모델은 실측 실내 holdout에서 활성 32.2%로 AbsRel 0.1595, δ_1 0.8262에 도달한다. 활성을 7.1%까지 낮춰 연산을 13분의 1로 줄이는 대가는 상대 AbsRel 13%이며, 그동안 원시 프레임 간 변동은 2.8배 감소한다. 반정밀도에서 프레임당 0.378 ms로 동작해 동급 규모 baseline보다 2.2배 빠르고 메모리는 2.4배 적으면서 정확도도 앞서지만, 30배 큰 제너럴리스트에는 정확도와 모션 보정 시간 오차에서 뒤진다.

네 가지 결과가 기여의 경계를 긋는다. 각각은 처음에 하려던 주장을 하나씩 좁힌다. 지배적 비용을 제거한 융합 스캔 커널은 동시에 데스크톱 GPU에서 희소 경로의 지연 시간 우위마저 없었고, 그 결과 희소성의 이득은 측정된 시간이 아니라 연산량과 메모리에서만 성립한다. 학습에 쓰지 않은 실측 주행 영상에서 정확도는 전이되지만 희소성은 전이되지 않는다 — 활성 비율이 26%에서 93%로 오르며, 모션 보정과 도메인별 임계 재조정을 거쳐야 14%로 되돌아온다. 희소 경로를 학습하지 않았던 이전 체크포인트에서 4배 붕괴했던 동일 마스크 토큰 제거 대조군은 지금 정확도상 동률이다 — **보존된 상태의 readout은 정확도가 아니라 시간 안정성을 산다.** 그리고 클립이 아니라 프레임 인덱스 별로 채점하면 유지된 상태가 스트림을 따라 정확도를 개선하지 않으며 동적 장면에서는 키프레임 사이에 **61% 악화한다** — 이 분야에서 관행인 8프레임 클립 평균은 그것이 서술하려는 스트리밍 설정에 대해 낙관적이다. 이 결과들은 정확한 변화 게이팅 상태 보존을 유용한 메커니즘으로 확립하는 동시에, 효율 주장이 성립하는 지점과 성립하지 않는 지점을 정확히 표시한다.

1. 서론

단안 깊이 추정은 빠르게 발전했지만, 이미지 모델을 비디오에 독립적으로 적용하면 두 가지 구조적 비효율이 남는다. 첫째, 장면 대부분이 변하지 않아도 프레임마다 거의 고정된 비용이 든다. 전경 움직임이 화면의 일부만 차지하는 고정 감시 카메라에서 특히 낭비가 크다. 둘째, 기저 기하가 안정적이어도 독립 예측은 흔들릴 수 있다. 비디오 전용 모델은 시간 일관성을 개선하지만, 대개 프레임별 dense 연산을 유지하거나 별도의 시간 정제 단계를 추가한다.

본 연구는 더 좁은 질문을 던진다: **SSM이 "시각적 변화 없음"을 시간 기억에 대한 정확한 no-op으로 취급할 수 있는가?** 선택적 SSM의 영차 유지(ZOH) 이산화가 직접적인 구성을 제공한다. 시간 간격에 이진 패치 마스크를 곱하면,

마스크된 갱신이 hidden state에 대한 항등 사상과 같아진다. 따라서 정적 패치는 학습된 근사나 피쳐 대체, 별도로 무효화되는 시간 캐시 없이 기억을 유지한다.

이 아이디어를 시간축·공간축 SSM 블록을 교차 적층한 스트리밍 비디오 깊이 구조 SOKKANAEM으로 구현한다. 경량 검출기가 이력 현상, 팽창, 주기적 키프레임으로 패치 활성 마스크를 생성한다. 센서 없는 GMC와 피쳐 공간 검출기가 이 메커니즘을 ego-motion으로 확장한다. 평가는 깊이 정확도와 원시 프레임 변동뿐 아니라 광학 흐름 워프 일관성(OPW), GT 기준 시간 일관성 오차(TCE), 상수 출력 대조군, 해석적 MAC, 실측 지연 시간까지 포함한다.

완료된 실험은 다섯 가지 결론을 뒷받침한다.

1. **정확한 상태 보존.** $M = 0$ 에서 Δ -게이팅은 구현상 비트 단위로 동일한 상태 복사를, 해석적으로는 항등 전이를 준다.
2. **유리한 희소성-정확도 교환.** 실험에서 활성을 96.2%에서 32.2%로 낮추는 대가가 상대 AbsRel 2.8%, 7.1%까지 낮추면 13%다.
3. **보존된 상태의 readout은 정확도가 아니라 시간 안정성을 산다.** 마스크를 맞춘 조건에서 Δ -게이팅을 토큰 제거로 바꿔도 정확도는 그대로이고 시간 지표 3종만 악화한다. 이전에 보고한 4배 정확도 붕괴는 학습되지 않은 희소 경로를 재고 있었다(\$5.4).
4. **효율 주장에는 날카로운 경계가 있다.** 융합 스캔 커널 이후 이 모델은 데스크톱 GPU에서 연산이 아니라 오버헤드에 묶여 있고, 모든 활성 수준에서 dense 실행이 희소 경로보다 빠르다. 희소성의 이득은 MAC과 스트림당 상태에서 확립돼 있으며, 시간·전력으로의 환산은 미측정이다(\$5.6).
5. **게이팅의 대가는 스트림을 따라 누적된다.** 유지된 상태는 프레임이 갈수록 정확도를 개선하지 않고, 동적 장면에서는 키프레임이 초기화하기 전까지 61% 악화한다. 클립 단위 평균이 이를 가리며, 표준 8프레임 프로토콜은 그 주기의 유리한 부분만 표본한다(\$5.7).

시간 일관성 전반의 우위라는 더 넓은 주장은 의도적으로 피한다. SOKKANAEM은 플리커 지향 지표인 원시 프레임 차이 오차에서 앞서지만, 현재 평가에서 모션 보정 지표나 GT 기준 지표는 Depth Anything 3와 Video Depth Anything이 더 강하다.

2. 관련 연구

2.1 단안 및 비디오 깊이

DPT와 Depth Anything 계열의 현대 단안 시스템은 강한 프레임별 깊이를 제공하지만 스트림을 가로지르는 지속 상태가 없다. 비디오 깊이 기법은 시간 어텐션, 모션 모듈, 후처리로 일관성을 개선한다. 주된 목표는 예측 품질이고 연산은 대체로 공간·시간 양쪽에서 dense하게 남는다. SOKKANAEM은 대신 조건부 시간 상태 갱신을 연구하며, 더 강한 사전학습 인코더·디코더와 상보적이다.

2.2 동적 토큰 및 변화 기반 연산

토큰 가지치기·병합·조기 종료는 이미지 내부 연산을 줄인다. DeltaCNN, skip convolution, eventful transformer는 프레임 간 변화를 활용하지만, 피쳐 캐시와 캐시 일관성 규칙으로 dense 출력을 보존하거나 복원해야 한다. SOKKANAEM은 변화한 영역만 재계산한다는 원리를 공유하되, 시간 정보를 SSM hidden state에 저장한다. 본 연구의 토큰 제거 ablation은 정적 토큰을 단순히 우회하는 것으로 충분한지를 직접 검증하며, 충분하지 않음을 보인다.

2.3 시각 상태공간 모델

시각 SSM은 이차 어텐션을 선형 스캔으로 대체하며 이미지와 비디오로 확장돼 왔다. 표준 변형들은 여전히 모든 토큰을 갱신한다. 본 연구의 기여는 외부에서 감지한 시각적 변화를 SSM 이산화 파라미터에 연결하고, 정확한 hidden

state 보존을 근사적 공간 출력 캐싱과 구별하는 데 있다.

3. 방법

3.1 개요




그림 1. 스트리밍 파이프라인. 변화 검출기가 연속 프레임을 패치 단위로 비교해 이진 활성 마스크를 내고, 그 마스크가 백본에 Δ -게이팅 신호로 전달된다. 정적 패치는 hidden state를 정확히 유지하며 연산이 생략된다. 공간 출력과 시간 hidden state, 두 캐시가 곱셈-누산 절감의 실제 출력으로 활성 15.4%에서 프레임당 1.644에서 0.608 GMAC으로 낮춘다. 전역 모션 보정 분기는 이동 카메라에서만 쓴다. 활성 40%를 넘는 프레임은 dense 경로로 우회한다.

프레임 I_{t-1} , I_t 에 대해 모델은 다음을 수행한다.

1. 이미지를 $p \times p$ 패치로 분할(완료된 본 실험은 $p = 16$);
2. 이진 활성 마스크 M_t 추정;
3. 현재 프레임 embed;
4. 시간축 Δ -게이팅 SSM과 공간축 SSM 블록을 교차 적용;
5. dense 깊이 지도 $\widehat{D}_t$ 디코딩;
6. 검출기 상태와 패치별 SSM 상태를 다음 프레임으로 전달.

상태 디저너리를 독립적으로 유지하므로, 가중치 한 벌로 여러 스트림을 상태 누출 없이 처리할 수 있다.

3.2 패치 변화 검출기

기본 픽셀 검출기는 패치 i 에 평균 제곱 변화를 할당한다.

$$s_{t,i} = \frac{\|P_{t,i} - P_{t-1,i}\|_2^2}{p^2 C}.$$

두 임계값으로 이력 현상을 구현한다.

$$M_{t,i} = \begin{cases} 1, & s_{t,i} > \tau_{\text{on}}, \\ 0, & s_{t,i} < \tau_{\text{off}}, \\ M_{t-1,i}, & \text{그 외.} \end{cases}$$

객체 경계를 보호하려고 활성 영역을 한 패치만큼 팽창시키고, 드리프트를 막으려고 K 프레임마다 전체 갱신을 강제한다. 평가 전용 ablation에서 픽셀 MSE와 코사인 검출은 같은 활성 비율에서 비슷했으므로 MSE를 기본으로 둔다. 완료된 3-arm 연구에서 i.i.d. 무작위 마스크 학습이 검출기 기반 미세조정보다 최소한 동등하게 강건했다.

3.3 정확한 Δ -게이팅




그림 2. 정확한 Δ -게이팅. 활성 마스크가 이산화 스텝에 곱해진다 ($\tilde{\Delta} = M\Delta$). 변화한 패치는 표준 selective-SSM 갱신을 받는다. 정적 패치는 $\bar{A} = I, \bar{B} = 0$ 이 되어 hidden state가 복원되는 것이 아니라 복사된다 — 연산을 건너뛰는 것을 보정하는 게 아니라, 그것이 상태 보존과 대수적으로 동일하다. 조기 종료와 토큰 제거는 대신 0이나 근사값을 대입하며, 그 오차는 프레임을 넘어 누적된다.

상태 행렬 A , 입력 투영 B , 시간 간격 Δ_i 를 갖는 연속 SSM의 ZOH 이산화는 다음과 같다.

$$\begin{aligned}\bar{A}_i &= \exp(\Delta_i A), & \bar{B}_i &= (\Delta_i A)^{-1} (\exp(\Delta_i A) - I) \Delta_i B, \\ h_i &= \bar{A}_i h_{i-1} + \bar{B}_i x_i, & y_i &= C_i h_i + D x_i.\end{aligned}$$

여기서 활성 마스크를 시간 간격에 적용한다.

$$\tilde{\Delta}_i = M_i \Delta_i.$$

$M_i = 0$ 이면

$$\bar{A}_i = I, \quad \bar{B}_i = 0, \quad h_i = h_{i-1}.$$

즉 정적 패치의 상태 전이는 정확히 항등이다. 중요한 것은 출력이 여전히 $C_i h_i$ 를 통해 보존된 상태를 읽을 수 있다는 점이다. 이 구별이 Δ -게이팅의 정확도와 연산 바닥을 동시에 설명한다 — 정확한 상태 보존이 정적 토큰의 모든 projection과 readout을 버려도 된다는 허가는 아니다.

3.4 시공간 백본

시간축 블록은 각 공간 패치를 프레임 축을 따라 스캔하므로, 그 hidden state는 고정된 이미지 위치에 묶인 기억이 된다. 공간축 블록은 프레임 내 문맥을 혼합한다. 두 블록을 교차하면 시간적 지속성과 공간적 추론이 결합된다. 보고하는 모델은 차원 192, 블록 4개, 상태 차원 16, 패치 크기 16이며 파라미터는 4,185,872개(fp32 가중치 16.7 MB)다.

선택적 공간 출력 캐시는 활성 패치를 모아 갱신하고 되돌려 놓으면서 정적 위치에는 이전 출력을 재사용한다. 시간축 Δ -게이팅과 달리 이 연산은 근사다 — 정적 공간 토큰이 새 문맥에 기여하지 않기 때문이다. 현재의 추론 전용 구현에서는 낮은 활성 비율에서만 유용하다.

3.5 이동 카메라 확장

카메라가 움직이면 원시 픽셀 차이가 조밀해진다. 따라서 저해상도 프레임에서 최대 50개 추적점으로 Lucas-Kanade 추적과 RANSAC을 써서 호모그래피를 추정한다. 이전 프레임을 현재 시점으로 워핑한 뒤 패치 embedding 간 상대 L_1 차이로 활성 마스크를 만든다. 추적 실패 시 항등 변환으로 폴백해, 변화를 조용히 억제하는 대신 활성 비율을 늘린다. §5.5가 같은 기전을 실찰 주행 영상에서 검증하며, 거기서도 성립하지만 **도메인별 임계 재보정을 거친 뒤에만** 그렇다 — 렌더링 영상에서 맞춘 피쳐 스케일 임계는 실찰 촬영에서 작동하지 않는다.

3.6 디코더와 목적 함수

보고된 체크포인트는 dense 업샘플링 디코더를 쓴다. 학습은 다음을 최소화한다.

$$\mathcal{L} = \mathcal{L}_{\text{SI-log}} + 0.5\mathcal{L}_{\text{grad}} + 0.1\mathcal{L}_{\text{temp}} + 0.05\mathcal{L}_{\text{normal}}.$$

무작위 마스크 스케줄링이 학습 중 스킵 비율을 높인다. 확정 체크포인트는 여기에 보조 손실 두 개를 더한다 — 광학 흐름으로 워프한 log-depth 잔차 항과 깊이 경계 가중 항이며, 둘 다 가중치 2.0이다.

실패한 실행 하나는 Kendall 방식 자동 손실 가중을 썼다. 최적화기가 temporal loss 가중치를 상한까지 밀어붙였고, 그 결과 상수 깊이 지도가 최적해가 됐다. 해당 체크포인트는 폐기하고 고정 가중치로 복귀했으며, 예측 분산 붕괴 감지기를 추가했다.

4. 실험 설정

4.1 데이터

주 합성 학습 혼합은 Virtual KITTI 2, TartanAir v2, PointOdyssey로 구성된다. 데이터셋 균형 샘플링이 가장 큰 소스의 지배를 막는다. 주 합성 holdout은 8,929 클립이며, 대표 비교는 모두 동일한 결정적 첫 1,000 클립을 쓴다.

배포 관련 실찰 도메인으로서는 TUM RGB-D 고정 카메라 시퀀스와 Bonn RGB-D Dynamic을 쓴다. RGB와 depth는 20 ms 이내 타임스탬프로 짝짓는다. 확정 체크포인트는 실찰 2종·합성 3종 위에서 60,000 스텝을 학습했다 (GPU 1장, 약 13시간).

초기 개념 검증은 Virtual KITTI 2 전체 코퍼스(42,520 프레임, 21,120 학습 클립)를 128픽셀에서 30k 스텝으로 사용한다.

교차 도메인 평가에는 학습에 쓰지 않은 KITTI raw 주행 5개 시퀀스(885 프레임)를 쓴다. 정답은 투영된 LiDAR로, 약 80 m에서 잘리고 유효 픽셀은 30%다.

4.2 지표

AbsRel, RMSE, δ_1 은 평가 프로토콜의 클립별 배율 정합 후 보고한다. 활성 비율은 검출기가 허용한 패치 갱신의 비율이다.

시간 지표는 다음과 같다.

- **t-delta**: 인접 프레임 출력 차이의 평균. 원시 플리커를 재지만 상수 출력에서 최소가 된다.
- **OPW**: RAFT-small 기반 광학 흐름 워프 예측 오차.
- **TCE**: 예측의 워프 잔차와 GT의 워프 잔차의 차이. GT 기하가 변할 때 상수 예측에 벌점을 준다.

모든 완전한 시간 지표 표에는 클립별 최적 상수 깊이 대조군이 포함된다. 이 대조군은 t-delta와 OPW의 퇴화를 드러내고 TCE의 데이터셋 고유 잔차 바닥을 제공한다.

4.3 Baseline과 구현

Depth Anything V2 Small(24.8M), Depth Anything 3 Base(120M), Video Depth Anything Small metric (28.4M)과 동일한 클립·동일한 지표 구현으로 비교한다. 지연 시간은 RTX 4090에서 배치 1로 측정한다. 해석적 곱셈-누산 수는 설정된 모델에서 유도한다. 예지 기기 결과는 아직 없다.

5. 결과

5.1 활성-정확도 교환 [체크포인트 종속]

기본 운용점을 재검토 중이다. §5.7이 여기서 쓰는 주기 30보다 10을 선호하며, 그것을 채택하면 이 절의 모든 활성 수치가 약 6포인트 올라간다.

이 절의 모든 표는 단일 체크포인트(4.19M 파라미터, 60k 스텝)에서 나온다. 어떤 비교도 모델 버전을 섞지 않는다. 각 행은 검출기 임계를 스위칭한 것이며, 소스당 100클립·데이터셋 균등 평균이다.

표 1. 두 도메인의 활성 스위칭. 상수 대조군은 클립별 최적 상수 예측이다.

τ_{on}	합성 활성 (%)	합성 AbsRel	합성 δ_1	실활 활성 (%)	실활 AbsRel	실활 δ_1	실활 t-delta
0.005	70.1	0.3734	0.4941	96.2	0.1552	0.8373	0.0836
0.02	60.2	0.3768	0.4880	74.0	0.1545	0.8365	0.0994
0.05 (기본)	49.6	0.3791	0.4821	32.2	0.1595	0.8262	0.0751
0.1	39.2	0.3814	0.4807	7.1	0.1753	0.8106	0.0299
상수 대조군	—	0.5504	0.3574	—	0.3581	0.5957	0.0000

실활에서 연산을 13분의 1로 — 활성 96.2%에서 7.1%로 — 줄이는 대가가 상대 AbsRel 13%이고, 기본 운용점인 32.2%에서는 2.8%다. 활성 74.0%에서는 오히려 전체 연산보다 정확도가 좋은데(0.1545 대 0.1552), 게이팅이 연산만 아끼는 것이 아니라 오래된 문맥을 끊는다는 해석과 부합한다. 모든 운용점 에서 상수 대조군과의 거리가 크게 유지되며, 이는 원시 t-delta 열만으로는 확인할 수 없는 사실이다.

합성 스위치가 낮은 활성까지 내려가지 못하는 것은 TartanAir가 임계와 무관하게 80~100% 활성으로 남기 때문이다. §5.5에서 정량화하는 것과 같은 현상으로, 스트림이 얼마나 건너뛴 수 있는지는 방법만이 아니라 촬영 조건의 성질이다.




그림 3. 활성 비율 대 정확도 — 실찰 실내와 합성 holdout에서 검출기 임계를 살펴본 결과. 정확도는 활성 약 30% 까지 거의 평평하다가 꺾인다. 실찰에서 연산을 13분의 1로 줄이는 대가는 상대 AbsRel 13% 이고, 기본 운용점(원 표시)은 2.8%다. 클립별 최적 상수 값이 대조군은 두 패널보다 한참 위에 있어 축 밖에 표시했다 — 그래야 세로축이 이 패널의 존재 이유인 곡선을 분해할 수 있다.

5.2 실찰 실내 결과 [체크포인트 종속]

합성만으로 학습한 이전 체크포인트는 실찰 실내 Kinect 깊이로 전이하지 못하고 상수 예측기에 패배했다. 혼합 도메인 미세조정이 이 실패를 뒤집으며, 학습 마지막 단계에서 추가한 보조 손실 두 개 — 흐름 워프 log-depth 잔차 항과 깊이 경계 가중 항 — 가 연산을 늘리지 않고 정확도와 시간 안정성을 함께 개선한다.

표 2. 실찰 실내 holdout(TUM, Bonn), 소스당 100클립, 데이터셋 균등 평균. 두 행의 활성 비율이 32.2%로 같으므로 개선을 연산으로 산 것이 아니다.

모델	AbsRel	RMSE (m)	δ_1	t-delta	OPW	TCE
직전 체크포인트	0.1633	0.6279	0.8211	0.0915	0.0271	0.0351
확정 체크포인트 (4.19M)	0.1595	0.6063	0.8262	0.0751	0.0243	0.0323

소스별로는 TUM에서 활성 19.7%로 AbsRel 0.1321· δ_1 0.8426, Bonn에서 활성 44.7%로 0.1869·0.8098이다. 합성 holdout에서는 AbsRel 0.3791·RMSE 14.22다.

두 가지 유의점이 있다. 두 체크포인트 사이의 합성 δ_1 차이는 측정된 seed 표준편차 ± 0.015 안이므로 주장하지 않는다. 더 중요하게, 두 행은 초기화 계보와 누적 스텝이 다르므로 표 2는 손실 항의 통제된 ablation이 아니라 체크포인트 비교다. 통제된 ablation은 8k 스텝에서만 존재하며 거기서는 순위가 오히려 반대였다. 짧은 프로브의 손실 항 순위가 수렴까지 살아남지 않았다는 점을 방법론적 발견으로 보고한다 — 짧은 프로브는 어떤 항이 도움이 되는지는 정할 수 있어도 얼마나 강하게 가중할지는 정할 수 없다.

5.3 더 큰 깊이 모델과의 비교 [체크포인트 종속]

표 3은 두 도메인 모두에서 단일 공통 프로토콜로 현행 baseline 체크포인트와 비교한다 — 소스당 100클립, 동일 holdout 시퀀스, 동일 지표 구현, 클립별 중앙값 정합.




그림 4. 비교군의 정확도 대 시간 안정성. 마커 면적은 파라미터 수의 로그에 비례한다. 두 축 모두 왼쪽 아래가 좋다. 본 모델은 각 패널에서 가장 작은 마커이며 안정성 축에서 가장 낮고 정확도 축에서 가장 오른쪽이다. 안정성 축이 로그인 이유는 t-delta가 비교군 전체에서 두 자릿수 넘게 퍼지기 때문이다 — 차순위 모델과의 격차가 실철에서 1.35배, 합성에서 4.2배다.

표 3. 단일 프로토콜 baseline 비교. 데이터셋 균등 평균이며 δ_1 을 제외하면 낮을수록 좋다.

모델	파라미터	도메인	AbsRel	δ_1	t-delta	TCE
Depth Anything 3 Base	120M	실철	0.1244	0.8790	0.1024	0.0252
Depth Anything V2 Small	24.8M	실철	0.2256	0.9050	0.9920	0.1015
SOKKANAEM (본 연구)	4.19M	실철	0.1595	0.8262	0.0751	0.0323
Depth Anything 3 Base	120M	합성	0.3618	0.4409	1.0128	0.0593
Depth Anything V2 Small	24.8M	합성	0.3818	0.7301	5.0124	0.1265
SOKKANAEM (본 연구)	4.19M	합성	0.3791	0.4821	0.2242	0.0622

세 가지로 읽는다. 30배 큰 제너럴리스트에는 정확도와 GT 기준 시간 오차에서 뒤지지만, 원시 프레임 간 변동은 실철에서 1.36배, 합성에서 4.5배 낮다. 동급 규모 모델과 비교하면 δ_1 을 제외한 모든 실철 지표에서 앞선다 — Depth Anything V2가 δ_1 은 높는데 AbsRel이 나쁜 이유는 클립별 배열·이동 정합 때문으로, 대부분의 픽셀 순위는 맞지만 원거리 몇 픽셀이 제곱 오차를 지배한다. 그리고 처리량에서는 순서가 완전히 뒤집힌다 — 반정밀도 + 컴파일에서 프레임당 0.378 ms 대 0.816 ms, 메모리 20.6 MB 대 49.6 MB다(\$5.6).

시간 일관성 전반의 우위는 주장하지 않는다. 시간 지표 세 가지 중 우리가 앞서는 것은 원시 프레임 차이 하나이고, 모션 보정 OPW와 GT 기준 TCE는 둘 다 Depth Anything 3가 낮다. 방어 가능한 주장은 파라미터와 지연 시간의 일부만으로 후처리 없이 플리커를 억제한다는 것이다.

5.4 보존된 상태의 readout이 실제로 사는 것 [체크포인트 종속]

Δ -게이팅은 정적 위치의 hidden state를 동결하지만 $C_i h_i$ 를 통해 여전히 그것을 읽는다. 토큰 제거 arm은 같은 마스크로 같은 상태를 동결하되 시간축 블록의 출력까지 우회한다. 둘을 비교하면 readout 자체의 가치가 분리된다.

표 4. 마스크를 맞춘 게이팅 위치 ablation(활성 49.6%), 확정 체크포인트, 합성 holdout. 두 arm 모두 temporal cache를 끈다 — Δ -게이팅 arm이 검증 대상인 dense readout을 실제로 수행해야 하기 때문이

다.

방식	AbsRel	RMSE	δ_1	t-delta	OPW	TCE
Δ -게이팅	0.3791	14.22	0.4821	0.2251	0.0309	0.0622
토큰 제거	0.3771	13.98	0.4866	0.2684	0.0337	0.0649

이 결과는 우리의 이전 발견을 뒤집으며, 우리는 이전 수치가 아니라 뒤집힘을 보고한다. 희소 경로가 학습에 포함되지 않은 추론 전용 근사였던 이전 체크포인트에서는 토큰 제거가 붕괴했다 — 활성 31.6% 에서 AbsRel 1.7178 대 0.4292로 4배다. 희소 경로를 학습 루프에 넣고 마스크 비율을 무작위화해 학습한 확정 체크포인트에서는 정확도가 사실상 동등이고(토큰 제거가 근소하게 앞서기까지 한다) 차이 전체가 시간 지표로 이동했다 — 원시 프레임 차이 19%, OPW 9%, TCE 4% 악화다.

정직한 해석은 이전 실험이 상태 readout의 가치가 아니라 학습되지 않은 희소 경로의 취약성을 재고 있었다는 것이다. 살아남는 주장은 더 좁지만 여전히 의미가 있다 — 보존된 상태를 읽는 것은 깊이 정확도가 아니라 시간 안정성을 산다. 정적 토큰의 결손을 견디도록 학습된 모델은 정확도를 스스로 회복하지만, 연속된 예측이 흔들리지 않게 하는 것은 readout뿐이다. 플리커 억제가 이 구조가 겨냥하는 성질이므로 이 ablation은 여전히 설계를 뒷받침한다 — 다만 처음 주장했던 것보다 작은 주장을 뒷받침한다.

5.5 교차 도메인 전이와 실 이동 카메라 [체크포인트 종속]

확정 체크포인트를 어느 학습 split에도 없는 KITTI raw 주행 5개 시퀀스(885 프레임)로 평가한다. 이 도메인의 합성 클론만 학습했으므로, 임의의 도메인 이동이 아니라 합성→실찰 축만 격리한다.

표 5. 실찰 주행 zero-shot과 in-domain 합성 holdout 비교.

설정	활성 (%)	AbsRel	RMSE (m)	δ_1	t-delta	TCE	중양값 비율
KITTI raw, zero-shot	92.8	0.2894	11.03	0.4955	2.0716	0.0995	2.630
Virtual KITTI 2 holdout, in-domain	25.8	0.3619	33.89	0.3943	0.3115	0.0243	0.760

정확도는 붕괴하지 않으며 명목상으로는 실찰 쪽이 낫다. 이 순서를 일반화 성과로 읽어서는 안 된다. 두 행은 난이도가 다른 문제를 풀기 때문이다 — 합성 holdout에는 256픽셀 입력이 분해할 수 없는 수백 m 구조가 있고, LiDAR 정답은 상한이 잘려 있으며 근거리로 집중돼 있다. 방어 가능한 서술은 합성 주행으로 학습한 표현이 실찰 주행에서도 쓸 만하게 남는다는 것까지다.

전이되지 않는 것은 희소성이다. 같은 장면 종류에서 활성 비율이 25.8%에서 92.8%로 오른다. 배포용 풀백을 끄고 검출기만 측정해도 같은 결과가 재현된다 — 픽셀 임계 0.05에서 합성 시퀀스는 패치의 7~10%가 활성인데 실찰 주행은 40~74%다. 센서 노이즈, 노출 변동, 롤링 셔터, 압축 아티팩트가 모두 변화로 등록된다. 따라서 고정 카메라에 대해 보고한 스킵 비율은 그 설정의 실측값이고, 합성 주행 비율은 낙관값이다.

이동 카메라 게이팅. 픽셀 게이팅과 GMC 피쳐 게이팅은 점수 척도가 다르므로 같은 임계에서 비교하는 것은 무의미하다 — 기본 임계에서 둘은 정확도상 구별되지 않으면서 GMC가 연산을 더 쓴다. 공정한 비교는 활성-정확도 곡선이다.




그림 5. 픽셀 게이팅 대 전역 모션 보정 피쳐 게이팅 — 실찰 주행 영상에서 곡선으로 비교. 두 전략은 변화를 서로 다른 척도로 채점하므로 곡선만 비교 가능하고 같은 임계의 점끼리는 비교되지 않는다. 같은 활성 비율에서 보정 방식이 두 축 모두 낮고, 활성 14%까지 내려가서도 픽셀 게이팅의 51% 지점을 이긴다.

표 6. 동일한 30클립, 두 게이팅 전략의 스왑.

게이팅	활성 (%)	AbsRel	δ_1	t-delta	TCE
픽셀	100.0	0.3083	0.5142	3.0852	0.1189
픽셀	92.7	0.3093	0.5089	3.1016	0.1236
픽셀	51.1	0.3357	0.4749	2.5108	0.1074
GMC + 피쳐	87.1	0.3065	0.5170	3.0533	0.1173
GMC + 피쳐	43.8	0.3084	0.5342	1.9319	0.0992
GMC + 피쳐	14.1	0.3178	0.5341	1.2314	0.0922

같은 활성 비율에서 GMC가 확실히 낮다 — 활성 43.8%에서 AbsRel 0.3084· δ_1 0.5342로, 픽셀 게이팅의 51.1%(0.3357·0.4749)를 더 적은 연산으로 이기며 상대 오차가 8.1% 낮다. GMC는 활성 14.1% 에서도 픽셀 게이팅의 51.1% 지점을 모든 지표에서 앞선다. GMC 곡선 내부에서는 연산을 7분의 1로 줄이는 대가가 상대 AbsRel 3.1%뿐이고 δ_1 과 시간 지표 둘 다 단조 개선되어, 그동안 시뮬레이션에서만 관찰되던 양상이 실찰에서 재현 된다.

실무적 유의점은 GMC의 기본 임계가 실찰 주행을 활성 100%로 둔다는 것이다. 올바른 서술은 "GMC를 켜면 충분 하다"가 아니라 "GMC와 도메인별 임계 보정을 함께 적용하면 픽셀 게이팅이 실찰 영상에서 잃는 희소성의 대부분을 되찾는다"이다.

5.6 연산량과 실측 지연 시간 분석

이 절의 두 결과는 반대 방향을 가리키며, 둘 다 중요하다.

해석적 연산량. 현재 구조는 전체 활성에서 프레임당 1.644 GMAC이 든다. 두 캐시를 쓰면 활성 15.4%에서 0.608 GMAC — 전체의 37.0%다. dense 바닥에서 디코더가 23.1%, 패치 embedding이 2.3%이므로 절감은 실재하며 희소성이 적용되는 백본에서 나온다.

실측 지연 시간. wall-clock을 지배한 것은 gather가 아니라 스캔 구현이었다. 활성 22% 희소 프레임을 프로파일 하면 71%가 공간축 스캔이고 활성 토큰의 수집·복원은 6%뿐이다. 레퍼런스 스캔은 청크 방식이라 청크마다 (B, C, C, P, S) 쌍별 감쇠 텐서를 실체화한다 — $L = 64, P = 384, S = 16$ 에서 0.4 MMAC을 계산하려고 약 25 MB를 옮긴다. 그래서 재귀를 레지스터에 유지하는 융합 Triton 커널로 대체했고, 추론에만 사용하며 학습은 미분 가능한 청크 경로를 유지한다. Δ -게이팅은 커널을 통과해도 비트 단위로 정확하고($\widetilde{\Delta} = 0$ 이면 $\exp(0) = 1$ 이고 입력 항이 0), 모든 평가 지표가 소수점 넷째 자리까지 불변이다.




그림 6. 융합 스캔 커널 전후의 프레임당 지연 시간 — RTX 4090 1장, 256픽셀, 배치 1, fp32, 활성 22%에서 측정. 모든 경로가 빨라졌고 순서가 뒤집혔다. 희소성이 아끼던 것이 스캔이었는데 그 스캔이 이제 거의 공짜가 되면서, 희소 경로에는 활성 비율에 비례하지 않는 부기 비용만 남았다.

RTX 4090 1장, 256픽셀, 단일 스트림, fp32, 활성 22%에서의 프레임당 지연 시간:

경로	청크 스캔	융합 커널	배수
전체 연산, eager	11.38 ms	1.98 ms	5.7배
전체 연산, 컴파일	4.70 ms	1.29 ms (776 FPS)	3.6배
희소, eager	4.87 ms	2.40 ms	2.0배
희소 + 버킷 패딩	5.39 ms	2.55 ms	2.1배
희소 + 버킷 + 컴파일	2.99 ms	2.04 ms (491 FPS)	1.5배

fp16에서 희소 경로는 1.69 ms(593 FPS), 최대 메모리 37 MB, 스트림당 지속 상태 6.38 MB다. 4개 스트림을 배치하면 전체 연산 경로에서 총합 2,060 FPS다. 반정밀도 + 컴파일 전체 연산은 0.378 ms(2,646 FPS, 20.6 MB)로, 같은 조건의 Depth Anything V2 Small(0.816 ms, 1,226 FPS, 49.6 MB)보다 2.2배 빠르고 메모리는 2.4배 적다.

역전. 커널 이전에는 활성 22%에서 희소 경로가 컴파일된 전체 연산보다 1.57배 빨랐다. 커널 이후에는 모든 활성 수준에서 컴파일된 전체 연산이 더 빠르다(1.29 ms 대 2.03~2.20 ms). 설명은 즉각적이다 — 희소성이 아끼던 것이 스캔인데 그 스캔이 이제 거의 공짜다. 남은 것은 활성 비율에 비례하지 않는 고정 비용, 즉 **nonzero** 수집, 열 우선 argsort, 버킷 패딩, 캐시 복사, scatter, 그리고 이들이 강제하는 호스트 동기화다. 이제 모든 경로의 지연 시간이 활성 비율에 평평하며(전체 연산은 활성 5~70% 구간에서 1.973~1.994 ms 사이), 이는 연산 제약이 아니라 오버헤드 제약 영역의 특징이다.

이 사실을 그대로 보고하는 이유는 기여의 경계를 긋기 때문이다. 정확한 상태 보존, MAC 절감, 커널 자체는 모두 성립한다. 회소 경로가 더 빠르다는 주장은 이 GPU에서 성립하지 않는다. 63%의 MAC 절감이 시간과 전력으로 환산되는지는 하드웨어가 연산 제약 상태인지에 달렸고, 이 규모의 4090은 그렇지 않다. 이를 가르려면 §7에 적은 예지 기기 측정이 필요하다.

5.7 스트리밍 드리프트 — 클립 단위 수치가 가리는 것 [검증 중]

이 절의 인과 주장 — 드리프트가 Δ-게이팅 자체가 아니라 학습-배포 불일치에서 온다는 것 — 을 검증하려고 클립 길이 24의 fine-tune이 실행 중이다. 성공하면 표 7·8과 권장 갱신 주기가 모두 바뀌고, 실패하면 불일치 설명이 틀린 것이며 드리프트는 내재적이다.

위의 모든 수치, 그리고 우리가 이제껏 보고한 모든 수치는 **8프레임 클립 평균**이다. 스트리밍 모델은 프레임을 가로질러 증거를 누적해야 하므로 프레임 7이 프레임 0보다 정확해야 한다 — 그것이 상태를 유지하는 이유다. 우리는 그것을 한 번도 측정하지 않았다.

32프레임 클립 안에서 프레임 인덱스별로 채점하되, 클립 단위 정합의 아티팩트를 배제하려고 프레임 마다 독립적으로 정합했다:




그림 7. 키프레임 사이에서 정확도가 악화한다. 패널 (a)는 32프레임 클립 안에서 프레임 인덱스별로 채점하되 각 프레임을 독립적으로 정합했다. 유지된 상태는 정확도를 누적하지 않는다 — 동적 객체 소스가 프레임 0에서 28까지 61% 악화하고, 프레임 31의 회복은 프레임 30에서 키프레임이 발동한 것이다. 패널 (b)는 갱신 주기를 쏘어, 해법이 이미 구조 안에 있고 단지 너무 드물게 적용될 뿐이며 주기가 10 아래로 내려가면 이 모델이 겨냥하는 안정성 우위를 잃는다는 것을 보인다.

표 7. 프레임 인덱스별 AbsRel. 키프레임 갱신 주기는 30프레임이다.

프레임	0	4	8	12	16	20	24	28	31
TUM	0.1353	0.1206	0.1249	0.1510	0.1521	0.1415	0.1585	0.1697	0.1323
Bonn	0.1642	0.1690	0.1795	0.1934	0.2185	0.2312	0.2431	0.2636	0.2011

누적 이득은 없고, 동적 장면에서는 누적 손실이 있다. TUM은 초반 몇 프레임에서 5%가량 좋아졌다가 이후 악화하고, Bonn은 0.1642에서 0.2636까지 단조 악화해 프레임 28에서 61% 나빠진다. 프레임 31의 회복은 키프레임이다 — 프레임 30에서 전체 갱신이 일어나 오차가 즉시 되돌아간다. **툼니 패턴**이다. 게이팅이 키프레임 사이에서 오차를 누적하고 키프레임이 그것을 지운다.

두 가지가 따라온다. 첫째, 해법은 이미 구조 안에 있고 단지 너무 드물게 적용될 뿐이다. 32프레임 클립에서 갱신 주기를 살펴보면:

표 8. 키프레임 주기 대 정확도·비용. 실찰 실내 holdout, 32프레임 클립.

주기	활성 (%)	AbsRel	δ_1	t-delta	TCE
5	45.0	0.1551	0.8280	0.1084	0.0368
10	35.3	0.1601	0.8233	0.0914	0.0355
15	32.4	0.1648	0.8142	0.0879	0.0357
30 (기본)	29.2	0.1774	0.7985	0.0813	0.0356
60	26.2	0.1807	0.7937	0.0697	0.0330

30 대신 10프레임마다 갱신하면 상대 AbsRel 9.8%와 δ_1 2.5포인트를 활성 6포인트로 되찾는다. 5까지 가면 정확도는 더 좋아지지만 t-delta가 0.1084로 올라 표 3에서 우리가 앞서는 유일한 지표를 잃는다. 주기 10에서는 0.0914로 여전히 1위다. 키프레임은 정의상 불연속이므로 정확도와 플리커 억제가 여기서 서로 교환된다.

둘째, 그리고 우리 결과를 어떻게 읽어야 하는지에 더 중요하게: 같은 체크포인트가 8프레임 클립에서 **0.1595**, 기본 주기의 **32프레임 클립에서 0.1774**를 낸다. 짧은 클립은 톱니의 유리한 부분만 표본한다. 배포는 수백 프레임을 돌리므로, 우리와 비디오 깊이 문헌 상당수가 쓰는 8프레임 관행은 그것이 서술하려는 스트리밍 설정에 대해 낙관적이다.

원인은 Δ -게이팅 자체의 결함이라기보다 학습-배포 불일치로 보인다. 학습은 4프레임 클립을 쓰므로 모델은 연속된 3프레임을 넘겨 상태를 유지해 본 적이 없다. 무작위 마스크 비율은 얼마나 많이 건너뛰는지에 강건하게 만들지만 얼마나 오래에는 그렇지 않다.

6. Ablation과 진단적 발견

6.1 마스크 정책

MSE와 코사인 변화 점수는 같은 활성 비율에서 비슷하다. 시험한 범위의 키프레임 주기는 짧은 클립 정확도에 거의 영향이 없다. i.i.d. 무작위 마스크 학습이 검출기 기반 마스크 미세조정보다 강건했는데, 이는 학습-배포 마스크 일치가 필수적이라는 초기 예상과 반대다.

6.2 DINOv2 피쳐 종류

최종 백본 토큰을 고정된 DINOv2-small 피쳐에 맞추는 것은 깊이 정확도를 개선하지 않는다 — AbsRel 0.4315 대 0.4292이며, 이전 체크포인트 쌍에서 측정했다. 시간 지표는 소폭 개선되므로(TCE 0.0846 대 0.0879), 더 나은 기하 표현이라기보다 정칙화로 보인다.

6.3 확정 체크포인트를 만든 설계 결정

최종 레시피의 세 가지 선택은 직관이 아니라 측정에서 나왔고, 각각 명시할 만한 대가를 치른다.

구간 분류 head. 회귀 손실과 함께 쓰는 64구간 교차 엔트로피 항은 실찰 AbsRel을 상대 8.6% 개선 한다 (0.1795 대 0.1963). arm당 seed 3개로 측정했으므로 효과가 seed 노이즈의 3~6배다. 공짜는 아니다 — 원시 프레임 차이 8%, TCE 12%를 대가로 낸다. 확정 모델은 이 항을 유지하고, 아래 보조 손실로 시간 지표를 되산다.

Dense 풀백. 활성 40%를 넘는 프레임을 dense 경로로 보내면 실찰 정확도가 개선되지만 (AbsRel 0.1685 → 0.1633, δ_1 0.8083 → 0.8211) 평균 활성이 22.2%에서 32.2%로 오른다. 이득이 동적 객체 소스에 몰려 있으므로, 기전은 불안정 회피가 아니라 오래된 공간 문맥을 끄는 것이다. 본 논문의 모든 속도 주장은 22.2%가 아니라 그 결과인 32.2%에서 인용한다.

보조 손실, 그리고 방법론적 경고. 깊이 경계 가중 항과 흐름 워프 잔차 항을 둘 다 가중치 2.0으로 켜다. 8k 스텝 스크리닝에서는 교환처럼 보였다 — 경계 항은 정확도를 개선하고 시간 지표를 악화시키며, 워프 항은 그 반대로 δ_1 을 노이즈 밖으로 악화시켰다. 60k 스텝에서는 그 교환이 사라지고 둘 다 함께 개선된다(표 2). **8k에서의 손실 항 순위가 수렴까지 살아남지 않았다.** 짧은 스크리닝 실행으로 손실 가중치를 정하는 것이 표준 관행이므로 이를 보고한다 — 우리 경우 그것은 어떤 항이 도움이 되는지 판단하는 데는 신뢰할 만했지만 얼마나 강하게 가중할지 정하는 데는 그렇지 않았다.

6.4 남은 정확도 오차의 소재

정답을 모델 자신의 출력 병목에 통과시키면 — 유효 픽셀에 대해 토큰 그리드로 평균 풀링, bilinear 복원, 중앙값 정합 — 완벽한 패치 토큰 head가 낼 수 있는 점수를 측정할 수 있다. 실찰 실내 holdout에서 현재 패치 크기 16의 상한은 TUM AbsRel 0.0844· δ_1 0.9140, Bonn 0.0651·0.9442인데 우리는 0.1321과 0.1869다. **자신의 구조적 상한보다 2~3배 위에 있으며, 그 상한은 이미 120M baseline의 AbsRel 0.1244를 능가한다.**

따라서 패치 크기와 입력 해상도는 병목이 아니다. 패치를 8로 줄이면 상한이 0.0466과 0.0306으로 올라가지만, 모델이 쓰지도 않는 여유를 사들일 이유가 없다. 모델과 현재 상한 사이를 가로막는 것은 용량, 최적화, 동적 장면 처리다.

격차는 한쪽에 몰려 있다. Bonn은 상한의 3배 위, TUM은 2배 위이고, Bonn이 움직이는 사람과 가림이 있는 소스다. Bonn 격차의 절반만 줄여도 데이터셋 균등 평균이 0.1595에서 0.13 아래로 내려간다. 이는 보조 손실 중 특정 용의자도 지목한다 — 흐름 워프 잔차 항은 광도 대응을 가정하는데, 움직이는 물체의 깊이 불연속에서 바로 그 가치가 깨진다.

이 측정은 틀리기 쉽다. 첫 버전은 유효성 마스크 없이 정답을 풀링해 센서 구멍이 평균에 섞였고, disparity 공간에서는 0 하나가 1/eps가 되어 패치를 지배하면서 TUM에서 AbsRel 11.4가 나왔다. 그 상태의 depth 공간 수치는 모델이 이미 상한을 넘어섰다는 정반대 결론을 시사했다.

6.5 범위 압축, 그리고 실패한 값싼 수정 [검증 중]

예측 log-depth의 폭을 정답에 맞추는 손실 항이 구현돼 대기 중이다. 아래의 진단은 어느 쪽이든 유지되며, 바뀔 수 있는 것은 마지막 문장 — 목적 함수에 압축을 벌하는 항이 없다는 부분이다.

§5.3은 두 정렬 규칙 모두로 우리 모델을 보고하며, 2 DOF 적합이 실찰 AbsRel을 0.1595에서 0.1321로 **17%** 개선한다. 자유도 하나가 그만큼 도움이 된다는 것은 1 파라미터 적합이 흡수하지 못하는 계통 오차가 있다는 뜻이다.

클립별로 쪼개면 위치가 잡힌다. 2 DOF 적합은 Bonn 클립의 78%에서 이득이지만(중앙 개선 9.6%) TUM은 31% 뿐이고 중앙 클립은 오히려 손해다. 같은 클립에서 예측과 정답의 disparity 분포를 재면 이유가 나온다:

표 9. 정답 대비 예측의 동적 범위.

소스	예측 5-95% 폭	정답 5-95% 폭	비율	std 비율
TUM	0.4068	0.4433	0.92	0.87
Bonn	0.4717	1.0068	0.47	0.44

Bonn에서 모델은 실제 동적 범위의 절반도 내지 못하고, 정답 범위가 2.3배 넓은 바로 그 소스에서 평균 쪽으로 회귀한다. 이 하나의 현상이 세 증상의 배후다 — 낮은 δ_1 (비율 지표는 납작해진 필드를 벌한다), Bonn 특이적 정렬 격차, 그리고 §6.4에서 Bonn이 구조적 상한의 3배 위에 있는 것.

명백한 용의자는 디코더였다. 구간 head는 로그 깊이 bin 중심에 대한 softmax 기댓값으로 깊이를 예측하고, 기댓값은 모델이 불확실할 때마다 분포 평균 쪽으로 끌린다. 이 가설은 재학습 없이 추론 시 softmax를 뽀족하게 만들어 검증할 수 있다:

온도	Bonn AbsRel	Bonn δ_1	범위비
1.00	0.2618	0.7315	0.58
0.50	0.2642	0.7320	0.59
0.25	0.2677	0.7278	0.58

범위비가 움직이지 않고 정확도는 오히려 조금 나빠진다. bin 분포는 이미 뽀족하며, 압축은 예측된 중심 자체에 있다. 모델이 실제로 납작한 필드를 예측한다. 이는 디코딩 수정을 배제하고 동시에 긴 클립 학습도 해법에서 배제한다 — 드리프트와 범위 압축은 원인이 다른 별개의 결함이다. 현재 목적 함수에는 압축을 벌하는 항이 없다. 스케일 불변 로그 손실이 불일치를 간접적으로 벌하긴 하지만, 불확실할 때는 예측을 줄이는 쪽이 여전히 손실을 낮춘다 — 통상의 편향-분산 교환이다.

7. 한계

본 연구에는 몇 가지 중요한 한계가 있다.

- §5의 모든 표는 단일 체크포인트에서 나오지만, §6의 진단 결과 두 개(마스크 정책, 피쳐 종류)는 이전 체크포인트에서 측정된 것이며 재실행하지 않고 그대로 표기했다.
- Video Depth Anything이 baseline 표에 없다. 로컬 체크아웃이 소실됐고 metric 가중치 재확보는 이번 라운드 범위 밖이었다. 따라서 비교는 24.8M~345M의 6종을 다루지만 **비디오 전용 baseline은 없다** — 시간 지표를 견주기에 가장 적절한 부류가 빠진 셈이다.
- OPW와 TCE는 시간 일관성 전반의 우위를 뒷받침하지 않는다. 원시 t-delta는 상수 예측으로 악용될 수 있으므로 정확도와 상수 대조군을 함께 놓고서만 해석한다.
- 융합 스캔 커널이 지배적 비용을 제거하면서, 동시에 RTX 4090에서 회소 경로의 wall-clock 우위도 제거했다. 이제 모든 활성 수준에서 컴파일된 전체 연산이 더 빠르다. 회소 경로에 남은 비용은 활성 비율과 무관한 부가 비용이다. 회소성의 이득은 현재 이 기기의 측정된 지연 시간이 아니라 MAC과 스트림당 상태에서 확립돼 있다.
- 이 규모에서 RTX 4090 실행은 오버헤드 제약 상태이므로 해석적 MAC 절감이 FPS로 이어지지 않는다. Jetson Orin 지연·에너지·다중 스트림 측정은 수행하지 않았으며, 그것이 MAC 절감의 배포 가치를 결정하는 측정이다.
- GMC는 실 ego-motion에서 검증됐지만(§5.5), 한 데이터셋의 주행 시퀀스 5개뿐이고 도메인별 임계 보정을 전제로 한다. 기본 임계는 실찰 영상에서 작동하지 않는다. 핸드헬드와 항공 모션은 미검증이다.
- 교차 도메인 평가는 실찰 주행만 다룬다. 미지의 실내 도메인(NYU, ScanNet)은 평가하지 않았다 — 전자는 호스트에 접속할 수 없었고 후자는 서명 동이가 필요하다. 따라서 일반화 주장은 한 장면 종류의 합성→실찰 측에 한정된다.
- 정확도가 키프레임 사이에서 악화하고, 보고한 클립 단위 수치는 그 주기의 유리한 부분을 표본하는 8프레임 클립에서 측정됐다(§5.7). 같은 체크포인트가 32프레임 클립에서는 0.1595가 아니라 0.1774다. 270프레임 너머는 미측정이며, 평평하기보다 더 나빠질 것으로 본다.

9. 예측 깊이 필드의 동적 범위가 동적 객체 소스에서 정답의 절반에 못 미친다(\$6.5). 결함의 위치는 특정했으나 고치지는 못했다. 목적 함수에 압축을 벌하는 항이 없다.
10. 패치 크기, 정제, 완전히 학습된 디코더/캐시 ablation은 미완이다.
11. 60k 결과는 단일 seed다. seed 분산은 8k에서만 특성화했으며(부록 A), 그 노이즈 바닥 아래의 차이는 어디에서도 주장하지 않는다.

8. 결론

SOKKANAEM은 패치 수준의 시각적 변화가 이산화 단계를 통해 SSM을 제어할 수 있음을, 즉 정적 관측을 시간 상태에 대한 정확한 항등 전이로 바꿀 수 있음을 보인다. 합성과 실촬영 RGB-D 평가 전반에서 공격적인 패치 희소성은 클립 안에서 깊이 정확도를 거의 잃지 않으며, 더 큰 baseline 6종 중 어느 것보다도 원시 프레임 간 플리커를 잘 억제 하면서 6~82배 작다.

실험은 이 아이디어의 경계도 함께 드러낸다. 정확한 상태 스킵은 종단 간 희소 추론과 동의어가 아니다 — dense readout, 공간 문맥, 디코딩이 남는다. 낮은 원시 프레임 변동이 모션 관점에서 올바른 시간 정확도를 보장하지도 않는다. 보존된 상태를 읽는 것이 결정적임을 증명한다고 읽었던 동일 마스크 토큰 제거 대조군은, 희소 경로를 학습시키고 나면 더 좁은 것을 증명한다 — readout이 사는 것은 안정성이고, 사는 것처럼 보였던 정확도는 학습되지 않은 경로의 아티팩트였다. 융합 스캔 커널은 커널 격차를 메웠지만 예상과 달리 데스크톱 GPU에서 dense 스트리밍을 더 빠른 구성으로 만들었고, 그 결과 효율 논증의 근거가 자연 시간에서 연산량과 메모리로 옮겨갔다 — 에지 기기가 판정할 때까지는 그렇다. 실 이동 카메라 평가와 교차 도메인 전이는 이제 측정됐고, 둘 다 그림을 확인해주기보다 날카롭게 만든다. 변화 게이팅은 방법만의 성질이 아니라 콘텐츠와 촬영 조건의 성질이기도 하다. 다음의 결정적 단계는 에지 기기 측정이며, 그것이 연산 절감이 배포에서 가치를 갖는지를 결정한다. 이 경계 안에서 정확한 Δ -게이팅은 변화 적응형 스트리밍 비전의 원리적 기반을 제공한다.

부록 A. 재현성 [체크포인트 종속]

모델. 차원 192, 시간축·공간축 교차 블록 4개, 상태 차원 16, 4방향 공간 cross-scan, depthwise 지역 합성곱 분기, 0.3~150 m를 64구간으로 나눈 head를 갖는 DPT 계열 디코더. 파라미터 4,185,872개, fp32 가중치 16.7 MB, 스트림당 지속 상태 fp32 12.75 MB / fp16 6.38 MB. 스트림 상태는 전부 외부 디스크너리에 있으므로 가중치 한 벌이 여러 스트림을 누출 없이 처리한다.

학습. 60,000 스텝, seed 0, 입력 256×256, RTX 4090 1장, 13시간 11분. 손실은 스케일 불변 로그 깊이 + 0.5 gradient + 0.1 temporal + 0.05 normal + 가중치 0.2의 64구간 교차 엔트로피 + 가중치 2.0의 보조 항 2종(흐름 워프 log-depth 잔차, 깊이 경계 가중). 마스크 비율은 검출기에서 가져오지 않고 학습 중 i.i.d.로 샘플링한다.

검출기 기본값. $\tau_{on} = 0.05$, $\tau_{off} = 0.025$, 1패치 팽창, 30프레임마다 키프레임 갱신, 활성 40% 초과 시 dense 폴백. GMC에서는 이 임계가 피쳐 스케일이며 도메인별 재보정이 필요하다(\$5.5).

평가. 소스당 100클립, 클립당 8프레임, holdout 시퀀스만, 모든 지표 산출 전 클립별 중앙값 정합. 시간 지표는 RAFT-small 흐름을 쓴다. 완전한 시간 지표 표에는 모두 클립별 최적 상수 깊이 대조군이 포함된다.

측정된 분산. seed 변동은 8k 스텝 실행 6회로 추정했다 — 실촬영 AbsRel ± 0.005 , 실촬영 $\delta_1 \pm 0.004$, 합성 $\delta_1 \pm 0.015$. 이보다 작은 차이는 본 논문 어디에서도 주장하지 않는다. 60k 실행은 단일 seed이므로 그 규모의 절대 수치에는 신뢰구간이 없다.

시간 측정 프로토콜. 배치 1, 256픽셀, 20회 워밍업 후 100회 반복, 3회 반복 중 최속, 다른 작업이 없는 GPU. 활성 비율은 검출기 stub으로 강제해 모든 구성에서 x축이 동일하며, 측정 중에는 dense 폴백 정책을 꺼서 각 구성이 실제로 측정되게 한다.

참고문헌

[draft.md](#)의 References 절과 동일하다. 제출 전 원문 대조가 필요한 항목도 그쪽에 표기했다 — Depth Anything 3, TartanAir V2, Video Depth Anything, Vision Mamba, Eventful Transformers, NVDS.