

SOKKANAEM

변화 패치 선택 연산 기반 실시간 비디오 깊이 추정

프레임 간 변화가 발생한 패치만 계산하는 스트리밍 깊이 추정 프레임워크

파라미터 4M

스트리밍 776 FPS

후처리 없는 프레임 간 안정성

랩 세미나 · 2026-08-18

비디오 깊이 추정의 연산 비용 문제

• 깊이 추정

- 한 장의 RGB 이미지에서 픽셀마다 카메라까지의 거리를 추정
- 출력은 입력과 같은 해상도의 거리 지도

• 응용 영역

- 고정 카메라 감시, 실내 모니터링, 로봇, 드론
- 공통 조건 — 영상이 끊기지 않고 들어오며 실시간 처리 필요

• 비디오에서 발생하는 비용 구조

- 대부분의 모델은 이미지 단위로 설계
- 30 FPS 영상이면 초당 30회의 전체 순전파
- 프레임 사이의 중복은 전혀 활용되지 않음

• 관찰

- 고정 카메라에서 프레임 간 변하는 영역은 소수
- 배경은 수백 프레임 동안 동일

데이터셋	촬영 성격	변화 패치
TUM	고정 실내	19.7%
PointOdyssey	실내외 합성	30.8%
Virtual KITTI 2	주행 합성	25.8%
Bonn	동적 객체 실내	44.7%
TartanAir V2	공격적 모션	92.1%

표 1. 데이터셋별 실측 변화 패치 비율 (16×16 패치, 변화 감지 임계 0.05)

고정 카메라에서는 프레임의 80%가 이전과 사실상 동일하다. 카메라가 크게 움직이면 이 여지가 사라진다 — 방법의 적용 범위를 규정하는 수치.

기존 접근의 한계와 연구 질문

• 기존 시간축 처리 방식

- 프레임별 독립 추정 후 시간축 후처리 평활화
- 명시적 시간 모듈 추가 (Chen et al., 2025)
- 다중 프레임 동시 입력 — 최신 대형 모델의 방식
- 공통점 — 연산량이 프레임 수에 비례하며 중복 계산을 줄이지 않음

• 연산을 줄이는 일반적 기법의 한계

- 조기 종료, 토큰 제거, 희소 연산이 존재
- 건너뛴 부분은 0 또는 근사값으로 대체
- 상태가 프레임을 넘어 이어지는 구조에서 **오차가 누적**
- 시간이 지날수록 예측이 드리프트

• 연구 질문

- 연산을 건너뛰면서도 건너뛴 토큰의 내부 상태를 **오차 없이** 유지할 수 있는가

• 가설

- 선택적 상태공간 모델의 이산화 파라미터가 이미 "입력을 상태에 얼마나 반영할지"를 제어 (Gu & Dao, 2023)
- 이 파라미터에 변화 마스크를 개입시키면 별도 모듈 없이 조건부 상태 제어가 가능


새 모듈을 추가하는 접근이 아니라, 모델이 이미 갖고 있는 제어 지점을 찾아 사용하는 접근.

Chen, S., Guo, H., Zhu, S., Zhang, F., Huang, Z., Feng, J., & Kang, B. (2025). Video Depth Anything: Consistent depth estimation for super-long videos. *CVPR*.

Gu, A., & Dao, T. (2023). *Mamba: Linear-time sequence modeling with selective state spaces*. arXiv:2312.00752.

Δ-게이팅의 수식 유도

Figure. Δ-게이팅 — 마스크를 이산화 파라미터에 곱하면 연산 스킵이 곧 상태 보존이 된다



핵심: 건너뛰었으므로 상태를 유지하는 것이 아니라, 건너뛴 결과가 상태 유지와 수식적으로 동일하다

조기 종료·토론 제거 등 일반적인 조건부 연산은 건너뛴 부분을 0 또는 근사값으로 대체하며, 그 오차가 프레임을 넘어 누적된다.

Δ-게이팅은 이산화 수식의 극한값 그 자체이므로 연속으로 여러 프레임을 건너뛰어도 상태 오염이 발생하지 않는다.

그림 1. Δ-게이팅 동작 원리 — 정적 패치에서는 상태 전이 행렬이 항등이 되고 입력 행렬이 0이 되어 은닉 상태가 그대로 복사된다.

① 기존 이산화 식

$$\bar{A}_i = \exp(\Delta_i A)$$
$$h_i = \bar{A}_i h_{i-1} + \bar{B}_i x_i$$

② 본 연구의 개입

$$\tilde{\Delta}_i = M_i \cdot \Delta_i$$
$$M_i \in \{0, 1\}$$

③ 정적 패치 대입 결과

$$\bar{A}_i = \exp(0 \cdot A) = I, \quad \bar{B}_i = 0$$
$$\implies h_i = h_{i-1}$$

정확한 상태 보존의 실험적 근거

주장	검증 방식	결과
상태 보존이 수학적으로 정확	마스크 0에서 상태 복사 비교하는 단위 테스트	비트 단위 일치
연산을 건너뛴 대가가 사실상 없음	스킵 비율을 올리며 정확도 측정	스킵 55%에서 저하 0.15%
이득의 원인이 Δ -게이팅임	동일 마스크로 토큰 제거 방식과 대조	Δ -게이팅이 우위

표 2. 세 가지 주장과 각각의 검증 방식

감지 임계	계산 패치	AbsRel ↓	$\delta 1$ ↑	변동 ↓
0 (전체)	100.0%	0.2054	0.684	0.1033
0.05	68.1%	0.2054	0.684	0.1002
0.10	44.6%	0.2057	0.684	0.0962

표 3. 스킵 비율에 따른 정확도와 시간 안정성 (합성 주행 데이터, 예비 실험)

- 절반 이상을 건너뛰어도 정확도는 **상대 오차 0.15%** 수준으로 유지 — 주행 영상처럼 전역 모션이 있는 조건에서도 성립
- **스킵 비율이 올라갈수록 프레임 간 변동이 오히려 단조 개선** — 시간 안정성이 후처리가 아니라 구조 자체에서 나온다는 근거

전체 파이프라인과 구성 요소

Figure. 제안 프레임워크의 처리 흐름




그림 2. 전체 파이프라인 — 변화 감지가 만든 마스크가 백본의 Δ -게이팅으로 전달되며, 두 종류의 캐시가 실제 연산 절감을 만든다.

- **변화 감지** — 패치 차이 + 이력 현상 + 팽창 + 키프레임 갱신
- **백본** — 시간축 · 공간축 상태공간 블록 교차 적층 (Liu et al., 2024)
- **디코더** — 밀집 예측 구조 (Ranftl et al., 2021) + 64구간 분류 · 회귀 (Bhat et al., 2021)
- **두 캐시** — 연산 절감의 실제 출처, 1.644 → **0.608 GMAC**
- **이동 카메라 확장** — 전역 모션 보정 후 변화 감지
- **고활동 풀백** — 변화 패치 40% 초과 시 전체 연산
- **모델 규모** — 4.19M 파라미터, 스트림당 상태 12.75MB

Bhat et al. (2021). AdaBins. *CVPR*. · Liu et al. (2024). VMamba. *NeurIPS*. · Ranftl et al. (2021). Vision transformers for dense prediction. *ICCV*.

학습 설정과 평가 프로토콜

데이터셋	종류	특성
TUM RGB-D	실찰	실내 고정 카메라
Bonn RGB-D	실찰	실내 동적 객체
Virtual KITTI 2	합성	주행, 조밀한 정답
TartanAir V2	합성	공격적 카메라 모션
PointOdyssey	합성	장기 시퀀스

표 4. 학습 및 평가에 사용한 데이터셋

- 학습에 사용하지 않은 시퀀스를 분리해 평가
- 데이터셋별 추출 확률 균등화
- **학습 설정** — 입력 256×256 , 60,000 스텝, GPU 1장, 약 13 시간
- 스케일 불변 로그 손실 (Eigen et al., 2014) + 구간 분류 손실, 보조 손실 2종

지표	정의	방향
AbsRel	예측과 정답의 상대 오차 평균	낮을수록
RMSE	제공 평균 제공근 오차 (m)	낮을수록
$\delta 1$	예측·정답 비율이 1.25 이내인 픽셀 비율	높을수록
프레임 간 변동	연속 프레임 예측의 평균 변화량	낮을수록
흐름 보정 불일치	광학 흐름 정렬 후의 예측 불일치	낮을수록
시간 일관성 오차	정답 기준 시간 방향 오차	낮을수록

표 5. 평가 지표 정의

프레임 간 변동은 출력이 상수일 때 최솟값이 되므로 단독 해석 금지. 정확도 수치는 클립 단위 중앙값 정합 후 산출 — 절대 거리 스케일은 주장하지 않는다.

Cabon, Y., Murray, N., & Humenberger, M. (2020). *Virtual KITTI 2*. arXiv:2001.10773. · Eigen, D., Puhrsch, C., & Fergus, R. (2014). Depth map prediction from a single image using a multi-scale deep network. *NeurIPS*. · Palazzolo, E., et al. (2019). ReFusion. *IROS*. · Sturm, J., et al. (2012). A benchmark for the evaluation of RGB-D SLAM systems. *IROS*, 573–580. · Wang, W., et al. (2020). TartanAir. *IROS*. · Zheng, Y., et al. (2023). PointOdyssey. *ICCV*.

깊이 추정 정확도와 외부 모델 대비 위치




그림 3. 파라미터 규모 대비 정확도 — 원의 크기는 프레임 간 변동, 작을수록 프레임 사이 흔들림이 적다.

모델	파라미터	AbsRel ↓	$\delta 1$ ↑	변동 ↓	시간 오차 ↓
대형 범용 모델	0.12B	0.1244	0.8790	0.1024	0.0252
동급 규모 모델	24.8M	0.2256	0.9050	0.9920	0.1015
제안 모델	4M	0.1595	0.8262	0.0751	0.0323


표 6. 실험 실내 홀드아웃 정확도 (소스별 100클립, 세 모델 동일 프로토콜)

- 30배 큰 대형 모델에는 **정확도와 시간 일관성 오차에서 열위**
- **원시 프레임 간 변동은 세 모델 중 최소** — 명시적 시간 모듈 없이 구조에서 확보
- 동급 규모 모델과 비교하면 $\delta 1$ 을 제외한 전 지표에서 우위
- 합성 데이터 AbsRel 0.3791, RMSE 14.22 — 원거리 구조가 많고 입력이 256px로 제한된 영향

시간 지표 세 가지 중 우위인 것은 원시 프레임 간 변동 하나. 주장은 후처리 없는 플리커 억제로 한정한다.

실측 처리 속도와 연산 절감

Figure. 융합 스캔 커널 전후의 프레임당 지연 시간 (변화 패치 22%)
단일 GPU · 입력 256×256 · 단일 스트림 · 단정밀도 · 3회 측정 최소값. 커널 적용 후에는 다섯 경로 모두 변화 패치 비율에 거의 무관하게 평평하다.



커널이 목표선을 통과시켰지만, 동시에 희소 경로가 존재하던 이유도 없었다.
희소 경로가 아까던 것이 바로 스캔인데 그 스캔이 거의 공짜가 되면서, 남은 것은 변화 비율과 무관한 고정 비용(토큰 수집·정렬·캐시 복사·동기화)뿐이다.
그 결과 이 GPU에서는 모든 변화 비율에서 전체 연산이 더 빠르다. 희소성의 이득은 현재 연산량(37.0%)과 스트림당 상태 메모리만으로 입증되어 있다.

그림 4. 융합 스캔 커널 전후의 프레임당 지연 시간 — 모든 경로가 빨라졌고, 가장 빠른 것은 희소가 아니라 전체 연산이 되었다.

경로	기존 스캔	융합 커널	배수
전체 연산, 컴파일 없음	11.38 ms	1.98 ms	5.7×
전체 연산, 컴파일	4.70 ms	1.29 ms (776 FPS)	3.6×
희소 + 버킷 + 컴파일	2.99 ms	2.04 ms (491 FPS)	1.5×

표 7. 변화 패치 22%에서의 프레임당 지연 시간 (단일 GPU, 256px, 단일 스트림). 커널 적용 후에는 모든 경로가 변화 패치 비율에 거의 무관하게 평평하다.

- **병목은 토큰 수집이 아니라 스캔이었다** — 희소 프레임의 71%가 스캔, 수집·복원은 합쳐 6%
- **원인** — 기존 스캔은 청크마다 쌍별 감쇠 텐서를 실체화, 40만 MAC을 위해 25MB를 이동
- **융합 커널** — 재귀를 레지스터에서 처리, 상태 보존은 여전히 비트 단위로 정확, **평가 지표 불변**
- **연산량** — 전체 1.644 GMAC, 변화 패치 15.4%에서 0.608 GMAC (37.0%)

목표선 2.34 ms는 통과했지만, 같은 커널이 희소 경로의 존재 이유도 없었다. 희소가 아
끼던 것이 바로 스캔이었고 그것이 거의 공짜가 되자 고정 비용만 남아, **이 GPU에서는
모든 변화 비율에서 전체 연산이 더 빠르다.** 희소성의 이득은 현재 연산량과 상태 메모리

한계와 향후 계획

• 현재 검증되지 않은 것

- 통계적 신뢰도 — 본 학습은 조건당 1회 실행이라 절대 수치에 신뢰 구간 없음
- 일반화 범위 — 동일 데이터셋의 다른 시퀀스로 분리했을 뿐 외부 도메인 일반화는 미검증
- 에지 디바이스 — 임베디드 지연 시간과 전력 미측정, 전력 이득 주장 불가
- 이동 카메라 확장 — 합성 데이터에서만 검증
- 절대 거리 스케일 — 중앙값 정합 기준이므로 미터 단위 절대 깊이 미주장

• 방법론적 교훈

- 짧은 예비 학습에서의 손실 항 순위가 장기 학습에서 역전됨을 관측
- 예비 실험은 채택 여부 판단에는 쓸 수 있으나 가중치 결정에는 부적합

항목	확정하는 주장	선행 조건
에지 디바이스 실측	연산량 절감이 시간·전력으로 환산되는지	기기 확보
외부 도메인 평가	일반화 범위	진행 중
논문화	—	위 항목 완료 후

표 8. 향후 계획과 각 항목이 확정하는 주장

요약

- ① 이산화 파라미터에 마스크를 곱하면 연산 스킵이 정확한 상태 보존과 수식적으로 동일해진다
- ② 4M 파라미터로 스트리밍 776 FPS, 프레임 간 변동은 30배 큰 모델보다 작다
- ③ 절대 정확도는 아직 열위이며 다음 관문은 전용 커널과 외부 도메인 검증

참고문헌

Bengio, Y., Léonard, N., & Courville, A. (2013). *Estimating or propagating gradients through stochastic neurons for conditional computation*. arXiv:1308.3432.

Bhat, S. F., Alhashim, I., & Wonka, P. (2021). AdaBins: Depth estimation using adaptive bins. *CVPR*, 4009–4018.

Cabon, Y., Murray, N., & Humenberger, M. (2020). *Virtual KITTI 2*. arXiv:2001.10773.

Chen, S., Guo, H., Zhu, S., Zhang, F., Huang, Z., Feng, J., & Kang, B. (2025). Video Depth Anything: Consistent depth estimation for super-long videos. *CVPR*.

Eigen, D., Puhrsch, C., & Fergus, R. (2014). Depth map prediction from a single image using a multi-scale deep network. *NeurIPS*, 27.

Gu, A., & Dao, T. (2023). *Mamba: Linear-time sequence modeling with selective state spaces*. arXiv:2312.00752.

Liu, Y., Tian, Y., Zhao, Y., Yu, H., Xie, L., Wang, Y., Ye, Q., & Liu, Y. (2024). VMamba: Visual state space model. *NeurIPS*, 37.

Palazzolo, E., Behley, J., Lottes, P., Giguère, P., & Stachniss, C. (2019). ReFusion: 3D reconstruction in dynamic environments for RGB-D cameras exploiting residuals. *IROS*.

Ranftl, R., Bochkovskiy, A., & Koltun, V. (2021). Vision transformers for dense prediction. *ICCV*, 12179–12188.

Sturm, J., Engelhard, N., Endres, F., Burgard, W., & Cremers, D. (2012). A benchmark for the evaluation of RGB-D SLAM systems. *IROS*, 573–580.

Teed, Z., & Deng, J. (2020). RAFT: Recurrent all-pairs field transforms for optical flow. *ECCV*, 402–419.

Wang, W., Zhu, D., Wang, X., Hu, Y., Qiu, Y., Wang, C., Hu, Y., Kapoor, A., & Scherer, S. (2020). TartanAir: A dataset to push the limits of visual SLAM. *IROS*.

Yang, L., Kang, B., Huang, Z., Zhao, Z., Xu, X., Feng, J., & Zhao, H. (2024). Depth Anything V2. *NeurIPS*, 37.

Zheng, Y., Harley, A. W., Shen, B., Wetzstein, G., & Guibas, L. J. (2023). PointOdyssey: A large-scale synthetic dataset for long-term point tracking. *ICCV*.